# Lineare Regression mit Mitteln der linearen Algebra

Anwendungen der linearen Algebra

Sebastian Domaschke

17. April 2026

# Der verlorene Planet

**Januar 1801, Palermo.**

Der Astronom Giuseppe **Piazzi** entdeckt einen neuen **Himmelskörper**, den Kleinplaneten *Ceres*. Er beobachtet ihn **41 Nächte lang**, dann verschwindet er hinter der Sonne.

**Das Problem:** Niemand weiss, wo er wieder auftauchen wird. Viele Beobachtungspunkte $(t_k, \text{Position}_k)$, aber die Bahn ist unbekannt.

**Carl Friedrich Gauss, 24 Jahre alt,** versucht das Problem zu lösen und entwickelt dabei eine neue Methode.

**Welche? Das ist Thema von heute.**

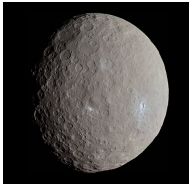

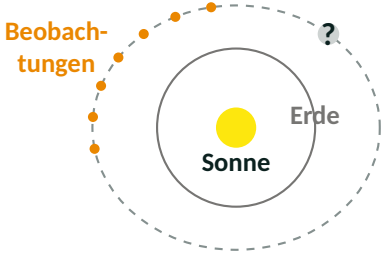

# Lernziele

- Die **Methode der kleinsten Fehlerquadrate** verstehen
- Die **Normalengleichung** $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$ aus der Orthogonalitätsbedingung herleiten
- Die Methoden **Lineare Regression**, **Polynomiale Regression** und **Multiple lineare Regression** verstehen, unterscheiden und anwenden

# Projektion eines Vektors auf einen anderen

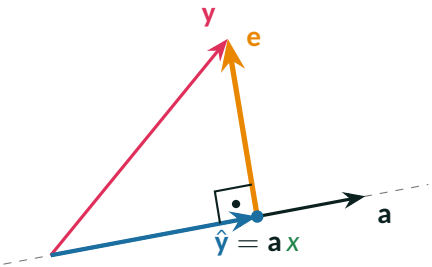


**Gesucht:** Skalar $x$, sodass $\hat{\mathbf{y}} = \mathbf{a}\,x$ den Vektor $\mathbf{y}$ bestmöglich approximiert.

**Bedingung:** Fehler $\mathbf{e} = \mathbf{y} - \mathbf{a}\,x$ steht *senkrecht* auf $\mathbf{a}$:

$$\mathbf{a}^\top \mathbf{e} = 0 \quad \Longrightarrow \quad \mathbf{a}^\top(\mathbf{y} - \mathbf{a}\,x) = 0$$

| | |
|---|---|
| $\mathbf{a}^\top \mathbf{y} = \mathbf{a}^\top \mathbf{a}\,x$ | Normalengleichung |
| $x = \dfrac{\mathbf{a}^\top \mathbf{y}}{\mathbf{a}^\top \mathbf{a}}$ | Lösung für $x$ |
| $\hat{\mathbf{y}} = \mathbf{a}\,x$ | Projektion |
| $\hat{\mathbf{y}} = \dfrac{\mathbf{a}\mathbf{a}^\top}{\mathbf{a}^\top \mathbf{a}}\mathbf{y} = H\,\mathbf{y}$ | Projektionsmatrix $H$ |

# Warum Projektion?

**Problem:** $A\mathbf{x} = \mathbf{y}$
lineares Gleichungssystem (Algebra)

**Bisher:** Lösbar — also $\mathbf{y} \in \text{Bild}(A)$

**Neu:** Problem erweitern — was wenn $A\mathbf{x} = \mathbf{y}$ *keine* Lösung besitzt?

Also $\mathbf{y} \notin \text{Bild}(A)$?

**Lösung:** Finde $\hat{\mathbf{x}}$, sodass $A\hat{\mathbf{x}} = \hat{\mathbf{y}}$ mit $\|\mathbf{e}\|$ minimal, also $\mathbf{e} \perp \text{Bild}(A)$
(Geometrie)

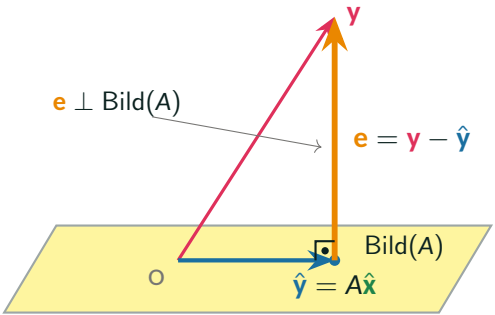


**Bemerkung:** Wir arbeiten im **Euklidischen Raum** $\mathbb{R}^n$ — damit ist die Norm immer die euklidische Norm $\|\mathbf{e}\|_2 = \sqrt{e_1^2 + \cdots + e_n^2}$.

# Herleitung der Normalengleichung

*Aus der Vorlesung bekannt:*

$A\colon \mathbb{R}^n \to \mathbb{R}^m$

$\mathrm{Bild}(A) = \{A\mathbf{x}\}$

$\mathrm{Kern}(A^\top) = \{\mathbf{v} \mid A^\top \mathbf{v} = \mathbf{o}\}$

$\mathrm{Bild}(A) \perp \mathrm{Kern}(A^\top)$

$\mathbb{R}^m = \mathrm{Bild}(A) \oplus \mathrm{Kern}(A^\top)$

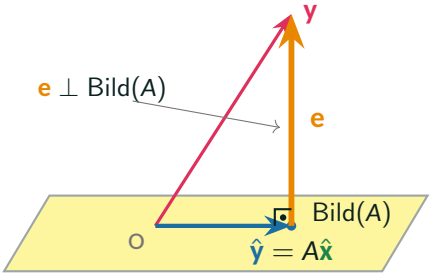


$\mathbf{e} \perp \mathrm{Bild}(A) \Rightarrow \mathbf{e} \in \mathrm{Kern}(A^\top) \Rightarrow A^\top \mathbf{e} = \mathbf{o}$

$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - A\hat{\mathbf{x}}$ einsetzen:

$A^\top(\mathbf{y} - A\hat{\mathbf{x}}) = \mathbf{o}$

## Methode der kleinsten Quadrate

(*Ordinary Least Squares*, OLS)

| | |
|---|---|
| $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$ | Normalengleichung |
| $\hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{y}$ * | Lösung für $\hat{\mathbf{x}}$ |
| $\hat{\mathbf{y}} = A\hat{\mathbf{x}}$ | Projektion |
| $\hat{\mathbf{y}} = H\,\mathbf{y}, \quad H = A(A^\top A)^{-1} A^\top$ | Projektionsmatrix |

* gilt, wenn $A^\top A$ invertierbar ist — wird später präzisiert.

# Beispiel 1: Lineare Regression konkret

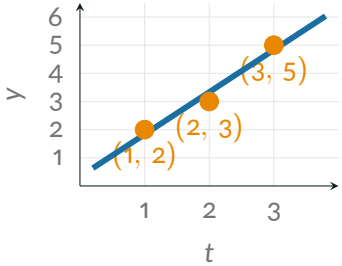


Modell: $y = m\,t + b$

$$m \cdot 1 + b = 2$$
$$m \cdot 2 + b = 3$$
$$m \cdot 3 + b = 5$$

$$\underbrace{\begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{pmatrix}}_{A} \underbrace{\begin{pmatrix} m \\ b \end{pmatrix}}_{\mathbf{x}} = \underbrace{\begin{pmatrix} 2 \\ 3 \\ 5 \end{pmatrix}}_{\mathbf{y}} \quad \Rightarrow \quad A\mathbf{x} = \mathbf{y}$$

**Normalengleichung** (OLS): $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$

$\Rightarrow \hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{y}$

$$\begin{pmatrix} \hat{m} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} 14 & 6 \\ 6 & 3 \end{pmatrix}^{-1} \begin{pmatrix} 23 \\ 10 \end{pmatrix}$$

$$\Rightarrow \quad \hat{m} = \tfrac{3}{2}, \quad \hat{b} = \tfrac{1}{3} \quad \Rightarrow \quad \hat{y} = \tfrac{3}{2}\,t + \tfrac{1}{3}$$

# Beispiel 2: Lineare Regression allgemein

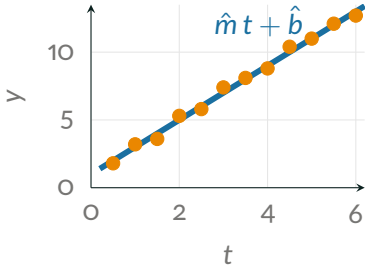


$$\underbrace{\begin{pmatrix} t_1 & 1 \\ t_2 & 1 \\ t_3 & 1 \\ \vdots & \vdots \end{pmatrix}}_{A} \underbrace{\begin{pmatrix} m \\ b \end{pmatrix}}_{\mathbf{x}} = \underbrace{\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \end{pmatrix}}_{\mathbf{y}} \Rightarrow A\mathbf{x} = \mathbf{y}$$

Modell: $y = m\,t + b$

$$\begin{aligned} m \cdot t_1 \; + \; b &= y_1 \\ m \cdot t_2 \; + \; b &= y_2 \\ m \cdot t_3 \; + \; b &= y_3 \\ &\vdots \end{aligned}$$

**Normalengleichung** (OLS): $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$

$\Rightarrow \hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{y}$

$$\hat{m} = \frac{\sum (t_k - \bar{t})(y_k - \bar{y})}{\sum (t_k - \bar{t})^2}, \qquad \hat{b} = \bar{y} - \hat{m}\,\bar{t}$$

mit $\bar{t} = \frac{1}{n}\sum_{k=1}^{n} t_k, \quad \bar{y} = \frac{1}{n}\sum_{k=1}^{n} y_k$

# Warum *kleinste Quadrate*?

**Der Fehlervektor** $\mathbf{e} = \mathbf{y} - A\hat{\mathbf{x}} = \mathbf{y} - \hat{\mathbf{y}}$ **:**

$$\min \|\mathbf{e}\|_2^2 \;=\; \min \sum_{k=1}^{n} \left(y_k - \hat{y}_k\right)^2 \;\widehat{=}\; \text{Summe der Fehlerquadrate}$$

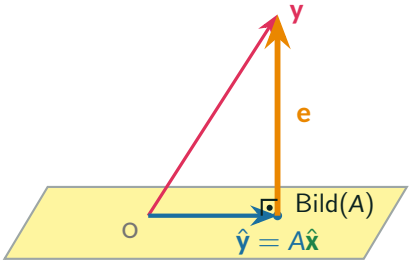


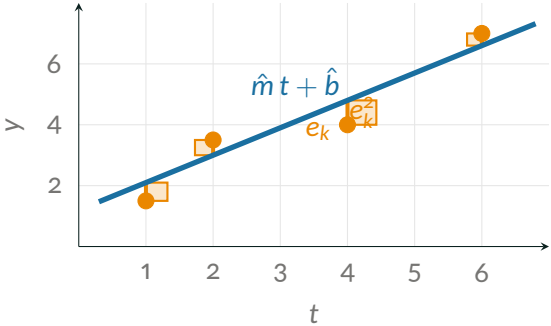

# Wann ist $A^\top A$ invertierbar?

$A^\top A$ invertierbar $\Leftrightarrow$ Spalten von $A$ **linear unabhängig**

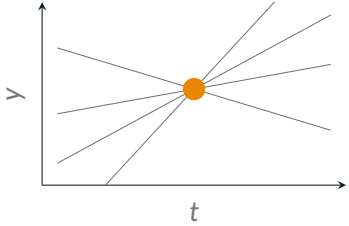


**Nur $n = 1$ Datenpunkt**
Unendlich viele Geraden möglich
$\Rightarrow$ keine eindeutige Lösung
$\Rightarrow A^\top A$ nicht invertierbar

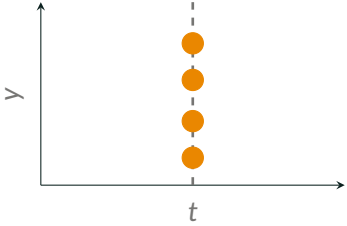


**Alle $t_k$ identisch**
Spalte 1 von $A = t_1 \cdot$ Spalte 2
$\Rightarrow \mathrm{Rang}(A) = 1$, nicht 2
$\Rightarrow A^\top A$ nicht invertierbar

Allgemein: weniger Daten als Parameter immer problematisch

# Erweiterungen

Die **Normalengleichung** $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$ gilt immer.
Nur die **Designmatrix** $A$ ändert sich:

| **Modell** | **Zeile $k$ von $A$** | **Unbekannte $\hat{\mathbf{x}}$** |
|---|---|---|
| Lineare Regression<br>$y = mt + b$ | $\begin{pmatrix} t_k & 1 \end{pmatrix}$ | $(m,\ b)^\top$ |
| Polynomiale Regression<br>$y = a_2 t^2 + a_1 t + a_0$ | $\begin{pmatrix} t_k^2 & t_k & 1 \end{pmatrix}$ | $(a_2,\ a_1,\ a_0)^\top$ |
| Multiple lineare Regression<br>$y = b + a_x x + a_y y + a_z z + \cdots$ | $\begin{pmatrix} 1 & x_k & y_k & z_k & \cdots \end{pmatrix}$ | $(b,\ a_x,\ a_y,\ a_z, \ldots)^\top$ |

$\Rightarrow$ **Live-Demonstration im Jupyter Notebook**

# Auflösung: Gauss findet den verlorenen Planeten

Gauss erfindet die **Methode der kleinsten Fehlerquadrate**, wendet sie auf Piazzis 41 Beobachtungspunkte an — und macht eine Vorhersage.

**Dezember 1801:** Ceres taucht exakt dort wieder auf, wo Gauss es vorhergesagt hatte — auf **0,5 Grad** genau.

Die Methode, die wir heute hergeleitet haben.

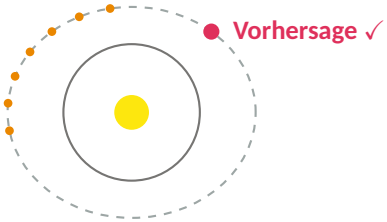


$$A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$$

# Weitere Anwendungen

**Machine Learning:** Jedes Neuron berechnet $\hat{y} = \mathbf{w}^\top \mathbf{x} + b$, das ist lineare Regression.

**GPS-Navigation:** Smartphone bestimmt Position durch Ausgleichsrechnung der Satellitensignale mittels kleinster Fehlerquadrate.

**Wissenschaftliche Messung:** Von der Teilchenphysik bis zur Klimaforschung: Beschreibende Funktionen aus verrauschten Messdaten extrahieren.

**Wirtschaft & Finanzen:** Ökonometrische Modelle für Inflation, Konjunktur und Marktprognosen.

**Ingenieurwesen:** Strukturanalyse, Signalverarbeitung und Regelungstechnik.

# Vergleich: Analysis-Herangehensweise

**Lineare Algebra:**
Orthogonalitätsbedingung

Bedingung $\mathbf{e} \perp \text{Bild}(A)$, also $A^\top \mathbf{e} = \mathbf{o}$:

$$A^\top(\mathbf{y} - A\hat{\mathbf{x}}) = \mathbf{o}$$

$$\Downarrow$$

$$A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$$

$$=$$

**Analysis:** Minimum der Kostenfunktion

Minimiere $f(\mathbf{x}) = \|\mathbf{y} - A\mathbf{x}\|^2$:

$$\nabla_{\mathbf{x}} f = -2A^\top(\mathbf{y} - A\mathbf{x}) \stackrel{!}{=} \mathbf{o}$$

$$\Downarrow$$

$$A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$$

Beide Wege führen zur **Normalengleichung**

# Rückblick auf Lernziele

- Die **Methode der kleinsten Fehlerquadrate** geometrisch als **Projektion** auf den Bildraum der Designmatrix verstehen
- Die **Normalengleichung** $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$ aus der Orthogonalitätsbedingung herleiten
- Die Methoden **Lineare Regression**, **Polynomiale Regression** und **Multiple lineare Regression** verstehen, unterscheiden und anwenden

# Anhang: Beispiel 1 — Manuelle Rechnung

$$A^\top A = \begin{pmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{pmatrix} = \begin{pmatrix} 14 & 6 \\ 6 & 3 \end{pmatrix}$$

$$A^\top \mathbf{y} = \begin{pmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \\ 5 \end{pmatrix} = \begin{pmatrix} 23 \\ 10 \end{pmatrix}$$

$$\det(A^\top A) = 14 \cdot 3 - 6 \cdot 6 = 6$$

$$(A^\top A)^{-1} = \tfrac{1}{6} \begin{pmatrix} 3 & -6 \\ -6 & 14 \end{pmatrix}$$

$$\begin{pmatrix} \hat{m} \\ \hat{b} \end{pmatrix} = \tfrac{1}{6} \begin{pmatrix} 3 & -6 \\ -6 & 14 \end{pmatrix} \begin{pmatrix} 23 \\ 10 \end{pmatrix} = \tfrac{1}{6} \begin{pmatrix} 9 \\ 2 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} \\ \frac{1}{3} \end{pmatrix}$$

$$\Rightarrow \quad \hat{y} = \tfrac{3}{2} t + \tfrac{1}{3}$$