Lineare Regression mit Mitteln der linearen Algebra

Anwendungen der linearen Algebra

Sebastian Domaschke

17. April 2026

Der verlorene Planet

Januar 1801, Palermo.

Der Astronom Giuseppe **Piazzi** entdeckt einen neuen **Himmelskörper**, den Kleinplaneten *Ceres*. Er beobachtet ihn **41 Nächte lang**, dann verschwindet er hinter der Sonne.

Das Problem: Niemand weiss, wo er wieder auftauchen wird. Viele Beobachtungspunkte $(t_k, \text{Position}_k)$, aber die Bahn ist unbekannt.

Carl Friedrich Gauss, 24 Jahre alt, versucht das Problem zu lösen und entwickelt dabei eine neue Methode.

Welche? Das ist Thema von heute.

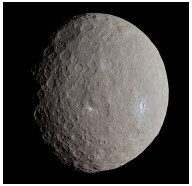

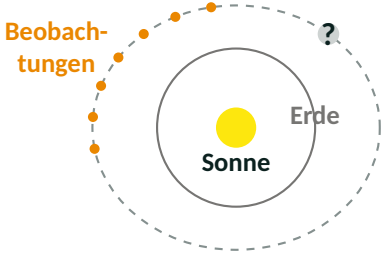

Lernziele

- Die **Methode der kleinsten Fehlerquadrate** verstehen
- Die **Normalengleichung** $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$ aus der Orthogonalitätsbedingung herleiten
- Die Methoden **Lineare Regression**, **Polynomiale Regression** und **Multiple lineare Regression** verstehen, unterscheiden und anwenden

Projektion eines Vektors auf einen anderen

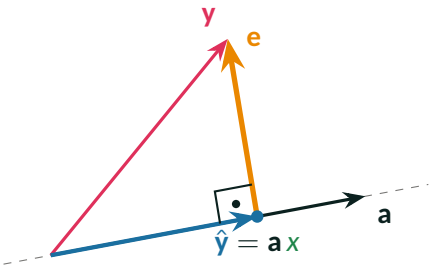

Gesucht: Skalar x, sodass $\hat{\mathbf{y}} = \mathbf{a}\,x$ den Vektor $\mathbf{y}$ bestmöglich approximiert.

Bedingung: Fehler $\mathbf{e} = \mathbf{y} - \mathbf{a}\,x$ steht *senkrecht* auf $\mathbf{a}$:

$$\mathbf{a}^\top \mathbf{e} = 0 \quad \Longrightarrow \quad \mathbf{a}^\top(\mathbf{y} - \mathbf{a}\,x) = 0$$

$\mathbf{a}^\top \mathbf{y} = \mathbf{a}^\top \mathbf{a}\,x$	Normalengleichung
$x = \dfrac{\mathbf{a}^\top \mathbf{y}}{\mathbf{a}^\top \mathbf{a}}$	Lösung für x
$\hat{\mathbf{y}} = \mathbf{a}\,x$	Projektion
$\hat{\mathbf{y}} = \dfrac{\mathbf{a}\mathbf{a}^\top}{\mathbf{a}^\top \mathbf{a}}\mathbf{y} = H\,\mathbf{y}$	Projektionsmatrix H

Warum Projektion?

Problem: $A\mathbf{x} = \mathbf{y}$
lineares Gleichungssystem (Algebra)

Bisher: Lösbar — also $\mathbf{y} \in \text{Bild}(A)$

Neu: Problem erweitern — was wenn $A\mathbf{x} = \mathbf{y}$ *keine* Lösung besitzt?

Also $\mathbf{y} \notin \text{Bild}(A)$?

Lösung: Finde $\hat{\mathbf{x}}$, sodass $A\hat{\mathbf{x}} = \hat{\mathbf{y}}$ mit $\|\mathbf{e}\|$ minimal, also $\mathbf{e} \perp \text{Bild}(A)$
(Geometrie)

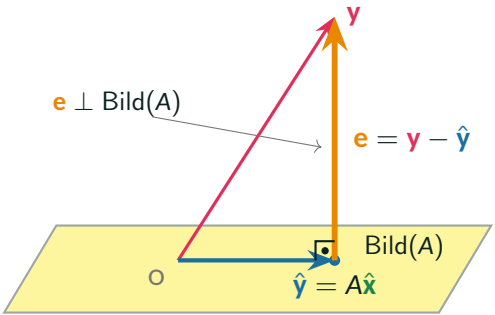

Bemerkung: Wir arbeiten im **Euklidischen Raum** $\mathbb{R}^n$ — damit ist die Norm immer die euklidische Norm $\|\mathbf{e}\|_2 = \sqrt{e_1^2 + \cdots + e_n^2}$.

Herleitung der Normalengleichung

Aus der Vorlesung bekannt:

$A\colon \mathbb{R}^n \to \mathbb{R}^m$

$\mathrm{Bild}(A) = \{A\mathbf{x}\}$

$\mathrm{Kern}(A^\top) = \{\mathbf{v} \mid A^\top \mathbf{v} = \mathbf{o}\}$

$\mathrm{Bild}(A) \perp \mathrm{Kern}(A^\top)$

$\mathbb{R}^m = \mathrm{Bild}(A) \oplus \mathrm{Kern}(A^\top)$

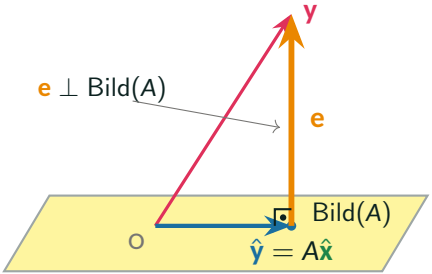

$\mathbf{e} \perp \mathrm{Bild}(A) \Rightarrow \mathbf{e} \in \mathrm{Kern}(A^\top) \Rightarrow A^\top \mathbf{e} = \mathbf{o}$

$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - A\hat{\mathbf{x}}$ einsetzen:

$A^\top(\mathbf{y} - A\hat{\mathbf{x}}) = \mathbf{o}$

Methode der kleinsten Quadrate

(*Ordinary Least Squares*, OLS)

$A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$	Normalengleichung
$\hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{y}$ *	Lösung für $\hat{\mathbf{x}}$
$\hat{\mathbf{y}} = A\hat{\mathbf{x}}$	Projektion
$\hat{\mathbf{y}} = H\,\mathbf{y}, \quad H = A(A^\top A)^{-1} A^\top$	Projektionsmatrix

* gilt, wenn $A^\top A$ invertierbar ist — wird später präzisiert.

Beispiel 1: Lineare Regression konkret

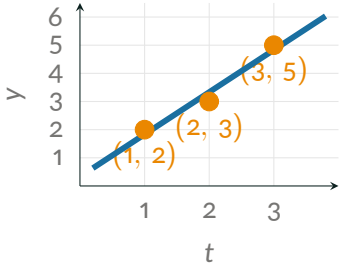

Modell: $y = m\,t + b$

$$m \cdot 1 + b = 2$$
$$m \cdot 2 + b = 3$$
$$m \cdot 3 + b = 5$$

$$\underbrace{\begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{pmatrix}}_{A} \underbrace{\begin{pmatrix} m \\ b \end{pmatrix}}_{\mathbf{x}} = \underbrace{\begin{pmatrix} 2 \\ 3 \\ 5 \end{pmatrix}}_{\mathbf{y}} \quad \Rightarrow \quad A\mathbf{x} = \mathbf{y}$$

Normalengleichung (OLS): $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$

$\Rightarrow \hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{y}$

$$\begin{pmatrix} \hat{m} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} 14 & 6 \\ 6 & 3 \end{pmatrix}^{-1} \begin{pmatrix} 23 \\ 10 \end{pmatrix}$$

$$\Rightarrow \quad \hat{m} = \tfrac{3}{2}, \quad \hat{b} = \tfrac{1}{3} \quad \Rightarrow \quad \hat{y} = \tfrac{3}{2}\,t + \tfrac{1}{3}$$

Beispiel 2: Lineare Regression allgemein

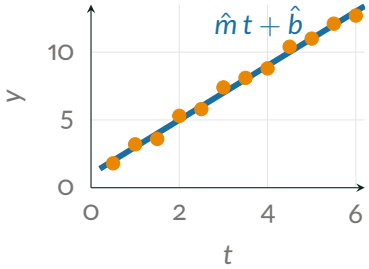

$$\underbrace{\begin{pmatrix} t_1 & 1 \\ t_2 & 1 \\ t_3 & 1 \\ \vdots & \vdots \end{pmatrix}}_{A} \underbrace{\begin{pmatrix} m \\ b \end{pmatrix}}_{\mathbf{x}} = \underbrace{\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \end{pmatrix}}_{\mathbf{y}} \Rightarrow A\mathbf{x} = \mathbf{y}$$

Modell: $y = m\,t + b$

$$\begin{aligned} m \cdot t_1 \; + \; b &= y_1 \\ m \cdot t_2 \; + \; b &= y_2 \\ m \cdot t_3 \; + \; b &= y_3 \\ &\vdots \end{aligned}$$

Normalengleichung (OLS): $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$

$\Rightarrow \hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{y}$

$$\hat{m} = \frac{\sum (t_k - \bar{t})(y_k - \bar{y})}{\sum (t_k - \bar{t})^2}, \qquad \hat{b} = \bar{y} - \hat{m}\,\bar{t}$$

mit $\bar{t} = \frac{1}{n}\sum_{k=1}^{n} t_k, \quad \bar{y} = \frac{1}{n}\sum_{k=1}^{n} y_k$

Warum *kleinste Quadrate*?

Der Fehlervektor $\mathbf{e} = \mathbf{y} - A\hat{\mathbf{x}} = \mathbf{y} - \hat{\mathbf{y}}$ **:**

$$\min \|\mathbf{e}\|_2^2 \;=\; \min \sum_{k=1}^{n} \left(y_k - \hat{y}_k\right)^2 \;\widehat{=}\; \text{Summe der Fehlerquadrate}$$

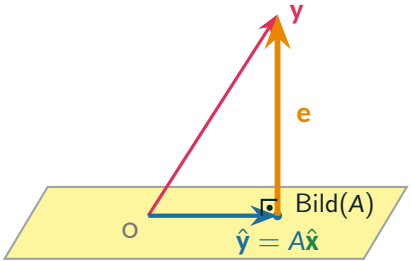

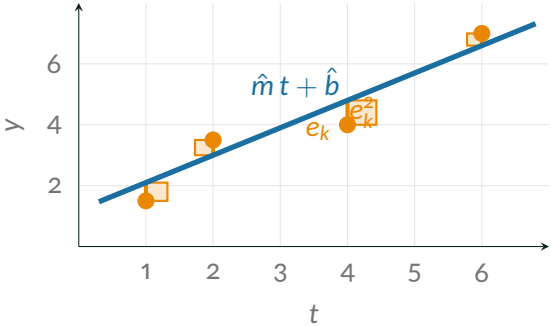

Wann ist $A^\top A$ invertierbar?

$A^\top A$ invertierbar $\Leftrightarrow$ Spalten von A **linear unabhängig**

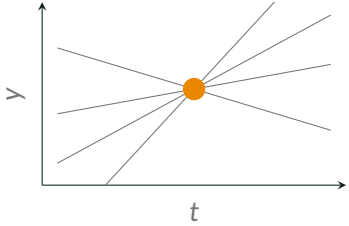

Nur $n = 1$ Datenpunkt
Unendlich viele Geraden möglich
$\Rightarrow$ keine eindeutige Lösung
$\Rightarrow A^\top A$ nicht invertierbar

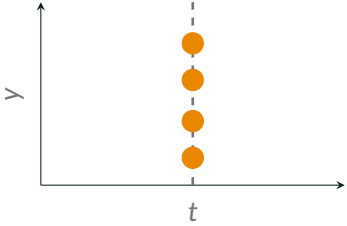

Alle t_k identisch
Spalte 1 von $A = t_1 \cdot$ Spalte 2
$\Rightarrow \mathrm{Rang}(A) = 1$, nicht 2
$\Rightarrow A^\top A$ nicht invertierbar

Allgemein: weniger Daten als Parameter immer problematisch

Erweiterungen

Die **Normalengleichung** $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$ gilt immer.
Nur die **Designmatrix** A ändert sich:

Modell	**Zeile k von A**	**Unbekannte $\hat{\mathbf{x}}$**
Lineare Regression $y = mt + b$	$\begin{pmatrix} t_k & 1 \end{pmatrix}$	$(m,\ b)^\top$
Polynomiale Regression $y = a_2 t^2 + a_1 t + a_0$	$\begin{pmatrix} t_k^2 & t_k & 1 \end{pmatrix}$	$(a_2,\ a_1,\ a_0)^\top$
Multiple lineare Regression $y = b + a_u u + a_v v + a_w w + \cdots$	$\begin{pmatrix} 1 & u_k & v_k & w_k & \cdots \end{pmatrix}$	$(b,\ a_u,\ a_v,\ a_w, \ldots)^\top$

$\Rightarrow$ **Live-Demonstration im Jupyter Notebook**

Auflösung: Gauss findet den verlorenen Planeten

Gauss erfindet die **Methode der kleinsten Fehlerquadrate**, wendet sie auf Piazzis 41 Beobachtungspunkte an — und macht eine Vorhersage.

Dezember 1801: Ceres taucht exakt dort wieder auf, wo Gauss es vorhergesagt hatte — auf **0,5 Grad** genau.

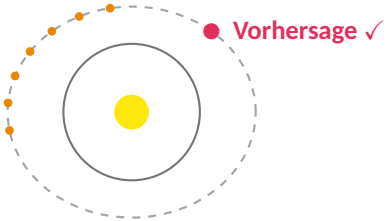

$$A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$$

Weitere Anwendungen

Machine Learning: Jedes Neuron berechnet $\hat{y} = \mathbf{w}^\top \mathbf{x} + b$, das ist lineare Regression.

GPS-Navigation: Smartphone bestimmt Position durch Ausgleichsrechnung der Satellitensignale mittels kleinster Fehlerquadrate.

Wissenschaftliche Messung: Von der Teilchenphysik bis zur Klimaforschung: Beschreibende Funktionen aus verrauschten Messdaten extrahieren.

Wirtschaft & Finanzen: Ökonometrische Modelle für Inflation, Konjunktur und Marktprognosen.

Ingenieurwesen: Strukturanalyse, Signalverarbeitung und Regelungstechnik.

Vergleich: Analysis-Herangehensweise

Lineare Algebra:
Orthogonalitätsbedingung

Bedingung $\mathbf{e} \perp \text{Bild}(A)$, also $A^\top \mathbf{e} = \mathbf{o}$:

$$A^\top(\mathbf{y} - A\hat{\mathbf{x}}) = \mathbf{o}$$

$$\Downarrow$$

$$A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$$

$$=$$

Analysis: Minimum der Kostenfunktion

Minimiere $f(\mathbf{x}) = \|\mathbf{y} - A\mathbf{x}\|^2$:

$$\nabla_{\mathbf{x}} f = -2A^\top(\mathbf{y} - A\mathbf{x}) \stackrel{!}{=} \mathbf{o}$$

$$\Downarrow$$

$$A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$$

Beide Wege führen zur **Normalengleichung**

Rückblick auf Lernziele

- Die **Methode der kleinsten Fehlerquadrate** geometrisch als **Projektion** auf den Bildraum der Designmatrix verstehen
- Die **Normalengleichung** $A^\top A\,\hat{\mathbf{x}} = A^\top \mathbf{y}$ aus der Orthogonalitätsbedingung herleiten
- Die Methoden **Lineare Regression**, **Polynomiale Regression** und **Multiple lineare Regression** verstehen, unterscheiden und anwenden

Folien und Jupyter Notebook:

`github.com/Boscij/linAlg`

Folien und Jupyter Notebook

github.com/Boscij/linAlg

Anhang: Beispiel 1 — Manuelle Rechnung

$$A^\top A = \begin{pmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{pmatrix} = \begin{pmatrix} 14 & 6 \\ 6 & 3 \end{pmatrix}$$

$$A^\top \mathbf{y} = \begin{pmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \\ 5 \end{pmatrix} = \begin{pmatrix} 23 \\ 10 \end{pmatrix}$$

$$\det(A^\top A) = 14 \cdot 3 - 6 \cdot 6 = 6$$

$$(A^\top A)^{-1} = \tfrac{1}{6} \begin{pmatrix} 3 & -6 \\ -6 & 14 \end{pmatrix}$$

$$\begin{pmatrix} \hat{m} \\ \hat{b} \end{pmatrix} = \tfrac{1}{6} \begin{pmatrix} 3 & -6 \\ -6 & 14 \end{pmatrix} \begin{pmatrix} 23 \\ 10 \end{pmatrix} = \tfrac{1}{6} \begin{pmatrix} 9 \\ 2 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} \\ \frac{1}{3} \end{pmatrix}$$

$$\Rightarrow \quad \hat{y} = \tfrac{3}{2} t + \tfrac{1}{3}$$